

# SISTEMA DE CLASIFICACION

Satisfacción y Segmentación de Clientes  
en E-commerce

INFORME PROYECTO FINAL  
BOOTCAMP DE INTELIGENCIA ARTIFICIAL, MACHINE  
LEARNING Y ANALITICA AVANZADA

Grupo # 4  
Emilio Palacín G.  
Oscar Espinoza  
Javier Ballén  
José Navarro



Profesor:  
Ing. Carlos Rafael Satizabal Sánchez

# Planteamiento

## CONTEXTO

---

- El sector e-commerce recibe grandes volúmenes de reseñas de clientes.
- La mayoría de este feedback es texto no estructurado.
- Analizar manualmente esta información no es viable.

## PROBLEMA

---

- La insatisfacción del cliente no se detecta a tiempo.
- Esto genera pérdida de clientes y decisiones tardías.

## NECESIDAD

---

- Transformar reseñas en información accionable mediante analítica avanzada

# Objetivo General

Desarrollar un modelo de clasificación y un sistema de análisis de datos que permita:


- . Predecir la satisfacción del cliente
- . Segmentar el mercado
- . Apoyar la toma de decisiones en e-commerce
- . Usando técnicas de Machine Learning y análisis de sentimiento



# Objetivos Específicos

- . Realizar análisis exploratorio de datos (EDA) e ingeniería de características.
- . Entrenar y validar modelos de clasificación para predecir recomendación del cliente.
- . Aplicar técnicas de clustering para segmentar clientes.
- . Visualizar resultados en un dashboard interactivo en Power BI.

Recuento de Calificación por Categoría



## Alcance

- .Dataset con 1.960 registros del sector retail.
- .Procesamiento y modelado en Python.
- .Modelos supervisados y no supervisados.
- .Visualización de indicadores clave.


```
--- INFO INICIAL ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2999 entries, 0 to 1999
Data columns (total 18 columns):
 #   Column      Non-Null Count  Dtype  
--- 
 0   ID_Cliente    2999 non-null   int64  
 1   Edad          1998 non-null   float64 
 2   Categoria     2999 non-null   object  
 3   Precio         2999 non-null   float64 
 4   Calificacion  2999 non-null   int64  
 5   Texto_Resena   1999 non-null   object  
 6   Fecha_Compra  2999 non-null   object  
 7   Recomendado   2999 non-null   int64  
 8   Departamento  2999 non-null   object  
 9   Tipo_Envio    2999 non-null   object  
dtypes: float64(2), int64(3), object(5)
memory usage: 156.4+ KB
None
>bound method DataFrame.head of
   ID_Cliente  Edad  Categoria  Precio  Calificacion \
0           1999    NaN  Chaquetas  39.76      5
1           1991   36.0  Vestidos  131.93      4
2           1992   19.0  Chaquetas  43.67      2
3           1993   29.0  Pantalones  15.95      1
4           1994   59.0  Chaquetas  64.46      4
...
1995        2995   37.0  Chaquetas  143.35      4
1996        2996   38.0    Blusas  29.84      3
1997        2997   41.0  Chaquetas  28.21      2
1998        2998   65.0  Accesorios  24.65      1
1999        2999   21.0  Pantalones  74.82      2
...
   Texto_Resena  Fecha_Compra  Recomendado \
0            NaN  2023-04-13          1
1  Totalmente recomendado, se queda perfecto.  2023-05-30          1
2            Mala calidad, costuras sueltas.  2023-06-10          0
3            El envío tardó demasiado y llegó dañado.  2023-02-28          0
4            Muy cómodo y elegante para la oficina.  2023-02-28          1
...
1995  Me encanta este producto, la tela es suave.  2023-02-28          1
1996            Llegó a tiempo, calidad aceptable.  2023-05-26          0
1997  El envío tardó demasiado y llegó dañado.  2023-01-14          0
1998            Talla incorrecta, es demasiado pequeño.  2023-03-05          0
1999  No lo recomiendo, muy caro para lo que es.  2023-02-17          0
...
   Departamento  Tipo_Envio
0       Ropa Mujer  Estándar
1       Deportes    Express
2       Ropa Hombre  Estándar
3       Ropa Hombre  Estándar
4        Niños      Estándar
...
1995    Deportes    Express
1996   Ropa Mujer  Estándar
1997   Ropa Hombre  Estándar
1998   Ropa Mujer  Estándar
1999     Niños      Estándar
```

## Metodología


### Metodología utilizada CRISP-DM (adaptada)

- . Comprendión del negocio
- . Comprendión de los datos
- . Preparación de los datos
- . Modelado
- . Evaluación
- . Visualización y análisis de resultados

Recuento de ID\_Cliente por Recomendado



Recuento de Categoría por Mes\_Nombre



# Tratamiento de Datos (Data Cleaning)

## Tratamiento de nulos en el DataFrame

### - Objetivo:

- Imputar los valores faltantes de la columna 'Edad' usando la mediana de esa columna
- Eliminar filas que no tengan texto en la columna 'Texto\_Resena' (importante para tareas de NLP).

### - Efectos:

- Modifica la columna 'Edad' rellenando NaN con la mediana actual de la columna.
- Elimina filas del DataFrame que tengan NaN en 'Texto\_Resena'.

### - Consideraciones:

- Se asume que `df` es un pandas.DataFrame y contiene las columnas 'Edad' y 'Texto\_Resena'.
- La imputación con la mediana preserva la escala central de la variable numérica.
- La eliminación de filas es crucial antes de convertir texto a vectores (p. ej. CountVectorizer).
- El uso de `inplace=True` en `dropna` modifica `df` en sitio.

```
1 import pandas as pd
2
3 df = pd.read_csv('/content/dataset_ecommerce_moda.csv')
4 df['Edad'] = df['Edad'].fillna(df['Edad'].median())
5 df.dropna(subset=['Texto_Resena'], inplace=True)
6 print(df.head)

... <bound method NDFrame.head of
1 1001 36.0 Vestidos 131.93 4
2 1002 19.0 Chaquetas 43.67 2
3 1003 29.0 Pantalones 15.95 1
4 1004 59.0 Chaquetas 64.46 4
5 1005 61.0 Chaquetas 78.01 5
...
1995 ... ...
1995 2995 37.0 Chaquetas 143.35 4
1996 2996 30.0 Blusas 29.04 3
1997 2997 41.0 Chaquetas 20.21 2
1998 2998 65.0 Accesorios 24.65 1
1999 2999 21.0 Pantalones 74.82 2

Texto_Resena Fecha_Compra Recomendado \
1 Totalmente recomendado, me queda perfecto. 2023-05-30 1
2 Mala calidad, costuras sueltas. 2023-06-10 0
3 El envío tardó demasiado y llegó dañado. 2023-02-28 0
4 Muy cómodo y elegante para la oficina. 2023-02-20 1
5 Superó mis expectativas, volveré a comprar. 2023-11-25 1
...
1995 Me encanta este producto, la tela es suave. 2023-02-28 1
1996 Llegó a tiempo, calidad aceptable. 2023-05-26 0
1997 El envío tardó demasiado y llegó dañado. 2023-01-14 0
1998 Talla incorrecta, es demasiado pequeño. 2023-08-05 0
1999 No lo recomiendo, muy caro para lo que es. 2023-02-17 0


Departamento Tipo_Envio
1 Deportes Express
2 Ropa Hombre Estándar
3 Ropa Hombre Estándar
4 Niños Estándar
5 Niños Estándar
...
1995 ... ...
1995 Deportes Express
1996 Ropa Mujer Estándar
1997 Ropa Hombre Estándar
1998 Ropa Mujer Estándar
1999 Niños Estándar

[1960 rows x 10 columns]>
```

# Análisis Exploratorio de Datos (EDA)


Visualización de la densidad demográfica y los picos de edad que definen el mercado objetivo.

```
1 # Gráfico 1: Distribución de Edades
2 plt.figure(figsize=(8, 5))
3 sns.histplot(df['Edad'], bins=20, kde=True, color='green')
4 plt.title('Distribución de Edad de los Clientes')
5 plt.savefig('grafico_edad.png') # Guarda la imagen
6 plt.show()
```



Identifica la variabilidad en la satisfacción (calificaciones) y detecta valores atípicos

```
1 # Gráfico 2: Calificaciones por Categoría
2 plt.figure(figsize=(10, 6))
3 sns.boxplot(x='Categoria', y='Calificacion', hue='Categoria', data=df, palette='viridis', legend=False)
4 plt.title('Distribución de Calificaciones por Categoría')
5 plt.savefig('grafico_boxplot.png')
6 plt.show()
```



# IA Aplicada - Modelo Supervisado

Validación de la precisión del modelo **Random Forest**.


Muestra qué tan bien el sistema predice si un cliente recomendará un producto (Verdaderos Positivos vs. Falsos Negativos).

```
1 y_pred = rf.predict(X_test)
2 print("\n--- REPORTE DE CLASIFICACIÓN (MODELO SUPERVISADO) ---")
3 print(classification_report(y_test, y_pred))
4
5 """
6 Visualización de la Matriz de Confusión.
7
8 - Objetivo:
9     Mostrar gráficamente el rendimiento del modelo de clasificación comparando
10    las etiquetas reales (y_test) con las predicciones (y_pred).
11
12    Línea 22. `sns.heatmap(...)`: Genera un mapa de calor con la matriz de confusión.
13        - `confusion_matrix(y_test, y_pred)`: Calcula la matriz (filas=real, columnas=predicho).
14        - `annot=True`: Muestra los valores numéricos en cada celda.
15        - `fmt='d'`: Formato entero para los números.
16        - `cmap='Blues'`: Paleta de colores azul.
17 - Interpretación de la matriz:
18     - Diagonal principal: Predicciones correctas (Verdaderos Positivos y Verdaderos Negativos).
19     - Fuera de la diagonal: Errores del modelo (Falsos Positivos y Falsos Negativos)
20 """
21 plt.figure(figsize=(6,5))
22 sns.heatmap(confusion_matrix(y_test, y_pred), annot=True, fmt='d', cmap='Greens')
23 plt.title('Matriz de Confusión')
24 plt.ylabel('Real')
25 plt.xlabel('Predicho')
26 plt.savefig('grafico_matriz.png')
27 plt.show()

...
--- REPORTE DE CLASIFICACIÓN (MODELO SUPERVISADO) ---
precision    recall  f1-score   support

      0       0.82      0.82      0.82      120
      1       0.92      0.92      0.92      272

   accuracy                           0.87      392
  macro avg       0.87      0.87      0.87      392
weighted avg       0.89      0.89      0.89      392
```



# IA Aplicada - Modelo No Supervisado


Visualización de la segmentación lograda con **K-Means**.

Es fundamental para que el área de Marketing entienda cómo se agrupan los clientes por su comportamiento de gasto y edad.

```
1 # Clustering: Agrupar clientes por Edad y Precio (Gasto)
2 X_cluster = df[['Edad', 'Precio']]
3 scaler = StandardScaler()
4 X_scaled = scaler.fit_transform(X_cluster)

1 # K-Means con 3 clústeres
2 kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
3 df['Cluster'] = kmeans.fit_predict(X_scaled)
4

1 """
2 Visualización de Clústeres mediante gráfico de dispersión.
3
4 - Objetivo:
5     Mostrar gráficamente la segmentación de clientes realizada por el algoritmo K-Means,
6     representando cada cliente según su Edad y Precio (gasto).
7
8 - Interpretación:
9     - Cada punto representa un cliente.
10    - Los colores indican a qué clúster pertenece cada cliente (0, 1 o 2).
11    - Permite identificar patrones de segmentación basados en edad y comportamiento de gasto.
12 """
13
14 plt.figure(figsize=(10, 6))
15 sns.scatterplot(x='Edad', y='Precio', hue='Cluster', data=df, palette='viridis')
16 plt.title('Segmentación de Clientes (K-Means)')
17 plt.savefig('grafico_cluster.png')
18 plt.show()
```



# SISTEMA DE CLASIFICACIÓN: Satisfacción y Segmentación de Clientes de E-Commerce

Total Clientes

1960

Nivel Promedio Satisfacción NPS (Proy)

69,03 %

Precio Promedio

7530

Satisfacción Global

3,59

Meses

1	4	7	10
2	5	8	11
3	6	9	12

Categoría

Accesorios	Pantalones
Blusas	Vestidos
Chaquetas	

Departamento


Deportes	Ropa Hombre
Niños	Ropa Mujer

Distribución de Recomendación por Categoría de Producto

Recomendado ● 0 % ● 100 %




Participación de Clientes por Estatus de Recomendación



Segmentación de Clientes por Cluster: Edad vs. Nivel de Gasto

Cluster ● 0 ● 1 ● 2



# Conclusiones y Recomendaciones

## Conclusiones

- Salud de Marca:** Se registra un NPS proyectado del 69,03%, lo que posiciona a la mayoría de la base como promotores.
- Segmento de Valor:** El Cluster 1 (Azul) agrupa a los clientes de mayor edad (40-70 años) con los tickets de compra más altos, siendo el segmento más rentable.
- Volumen Operativo:** La categoría de Accesorios lidera en cantidad de transacciones, representando el mayor flujo de datos del sistema.
- Nivel de Satisfacción:** La calificación global de 3,59 indica un margen de mejora operativa, especialmente en el 30,97% de clientes que no recomiendan el servicio.

## Recomendaciones

- Enfoque en Rentabilidad:** Priorizar campañas de fidelización para el Cluster 1, dado su historial de compras de alto valor.
- Acción Correctiva:** Investigar los factores de insatisfacción en el 31% de detractores para elevar la Satisfacción Global por encima de 4,0.
- Estrategia de Crecimiento:** Implementar tácticas de *cross-selling* en la categoría de Pantalones, que actualmente muestra el volumen más bajo de clientes.
- Estabilización de Precios:** Desarrollar incentivos para que el Cluster 0 (Verde) incremente su gasto por encima del promedio actual de 7.530.

# Gracias!